

통계적 시계열 모형 Prophet을 활용한 서울시 지하철 혼잡도 예측 및 기상 변수가 미치는 영향력 분석

주제	기상과 지하철 혼잡도 상관 분석·예측		
참가번호	250125	팀명	꿀통들

□ 분석 배경 및 목표

○ (분석 목적)

- 통계적 시계열 모형 Prophet을 활용하여 서울시 각 노선별 지하철 혼잡도를 예측하고, 기상 변수가 지하철 혼잡도에 미치는 영향력을 분석하여, 기상 조건에 따른 지하철 이용 패턴의 변화를 정량적으로 파악하는 것이 목적임.

○ (분석 배경)

- 서울시 지하철 역 혼잡도는 주로 유동 인구, 출퇴근 시간, 평일/주말 여부 등 시간적 요인에 의해 영향을 받기 때문에, 기상 변수의 영향력을 명확히 분석하기 어려운 한계점이 존재함.
- 기상청에 의하면 폭염, 폭설 등의 극단적인 기상 요건이 자가용 대신 대중교통을 이용하는 수단전이 현상이 관찰되며, 이는 기상 요인이 지하철 이용에 영향을 주는 증거로 볼 수 있음. - [1]

○ (분석 목표)

- Prophet을 통해 지하철 혼잡도가 가지는 시간적 주기성을 반영하고, 기상 변수와 같은 외생 변수를 추가함으로써 혼잡도 예측의 정밀도를 높이하고자 함.
- 모형 적합 결과를 기반으로, 예측에 영향을 많이 주는 시간대와 기상 조건에 따른 평균 변화를 시각화하여, 혼잡도 변화를 정량적인 수치로 비교 및 분석하고자 함.

□ 분석 데이터 변수

<표 1>. 데이터 변수 설명

구분	변수명	내용	범위/단위	출처
제공 데이터	날짜	날짜 및 시각	2021-01-01 - 2023-12-31	기본 제공 데이터
	호선	지하철 호선	서울시 지하철 1-8 호선	기본 제공 데이터
	역명	역 명	서울시 지하철 324 역	기본 제공 데이터
	상하구분	지하철 상행 하행 구분	상행/하행/외선/내선	기본 제공 데이터
	기온	정시 기온	°C	기본 제공 데이터
	풍속	정시 10분 평균 풍속	m/s	기본 제공 데이터
	일강수량	0~24시까지의 일 강수량	mm	기본 제공 데이터
	시간강수량	1시간 강수량	mm	기본 제공 데이터
	상대습도	정시 상대 습도	%	기본 제공 데이터
	체감온도	500m 객관분석 자료	°C	기본 제공 데이터
파생 변수	혼잡도	열차 내 혼잡도	%	기본 제공 데이터
	요일	요일 더미 변수	(월, 화, 수, 목, 금)	파생변수
	시간	시간 더미 변수	00-23(시간 구분)	파생변수
	요일*시간	요일-시간 상호작용 변수	-	파생변수
	풍향-sin	풍향 변수 sin 함수 변환	-	파생변수
	풍향-cos	풍향 변수 cos 함수 변환	-	파생변수
	불쾌지수	기온과 상대습도 간의 관계	-	파생변수
	공휴일	공휴일 여부	공휴일 여부: 1/0	파생변수
외부 데이터	공휴일*시간	공휴일-시간 상호작용 변수	-	파생변수
	적설량	적설값	(cm)	기상청 API 허브


□ EDA

○ (지하철 혼잡도 데이터가 가지는 시계열 주기성 특성)

- <그림1>은 2021년부터 2023년까지 서울시 모든 지하철 역의 평균 혼잡도 변화를 나타낸 것으로, 연도별로 혼잡도 변화가 전반적으로 증가하는 추세를 확인할 수 있음.

- 지하철 혼잡도가 증가하는 추세의 원인으로 코로나 19 이후 대중교통 이용량 회복과도 관련된 변화로 해석 됨.

- 각 연별 1~5월, 9~11월 구간에는 평균 혼잡도가 증가하는 반면, 6~8월 구간에는 다시 감소함.



<그림 1> 2021~2023년 일 평균 혼잡도

- <그림 2>와 <그림 3>에서는 각 지하철 호선별 시간대와 요일에 따른 혼잡도 분포를 Boxplot을 통해 나타낸 것임.

- 모든 호선에서 출근 시간대(07-09시) 보다 퇴근 시간대(17-19시)에 혼잡도가 더 높은 경향을 나타내고, 주말에 비해 평일에 혼잡도가 더 높은 경향을 보임.




그림 2. 출·퇴근에 따른 지하철 평균 혼잡도 분포




그림 3. 평일·주말에 따른 지하철 평균 혼잡도 분포

□ 외부 데이터

○ (적설량 외부데이터)

- 적설량은 대중교통(지하철, 버스 등) 이용에 영향을 줄 수 있는 외부 기상 변수로 간주함.

- (적설량 추출) 기상청 API 허브에서 제공하는 지상관측-적설관측 중 2021~2024년 1시간 단위 적설량을 추출함. - [2]

- (적설량 병합) 해당 추출된 적설량 자료 중 STN_ID(지점번호)가 서울에 해당하는 데이터를 선별한 후

에 기본 제공된 지하철 혼잡도 데이터와 1시간 단위 기준으로 병합함.

□ 데이터 전처리

○ 결측치 처리

- 기상 변수 중에서 -99 값을 가지는 값을 결측치(NA)로 간주하였고, 특히 풍향 변수는 -99 값 외에도 -9.9 등 기상관측 오류에 해당하는 비정상 값이 포함되어, 결측치로 처리함.
- (시계열 보간법) 각 호선, 상하구분, 역명 단위로 데이터를 그룹화한 후에, 시간 순으로 다시 정렬하여 시계열 기반 선형 보간법을 적용하였음.
- (양방향 보간법) 각 역에 대해 선형 보간 이후에도 남은 결측값은 ‘forward/backward fill’ 방식을 적용하여 양방향으로 보간하여, 남은 모든 결측치를 대체함.

○ 파생 변수 생성

- (시간 주기성 반영) <그림 1>, <그림 2>의 EDA 결과에 따라, 지하철 혼잡도 데이터는 추세성, 요일 및 시간대에 따라 강한 시계열 주기성을 가지기 때문에, 이러한 특성을 모델에 반영하고자 요일, 시간 변수를 One-hot encoding하여 파생 변수를 생성하였고, 요일*시간의 상호작용 항도 추가하여 복합적인 시간 패턴을 효과적으로 반영하고자 함.
- (비선형 풍향 변수) 풍향은 0~360도 범위의 각도로 주어지며, 선형적으로 표현할 수 없는 부분을 보완하기 위해 사인(sin)과 코사인(cos) 함수로 변환하여 각도의 주기성과 방향성을 보존한 형태로 재구성 하였음.
- (불쾌지수 변수) 불쾌지수는 기온과 상대습도 값을 기반으로 산출되는 지표로, 고온다습 환경에서 인간이 느끼는 심리적 불쾌감을 수치화 한 것임.
- 불쾌지수는 지하철 이용과 관련해 간접적인 영향을 미칠 수 있는 변수로 간주 하여, 다음 <식 1>과 같이 계산하여 파생변수로 생성함. - [3]

$$\text{불쾌지수} = 0.08 * \text{기온} + 0.01 * \text{상대습도} * (0.99 * \text{기온} - 14.3) + 46.3 \quad \text{<식 1>}$$

□ 분석 방법

○ (Prophet 시계열 모형) - [4]

- 지하철 호선별, 역명, 상하행별로 모두 개별적으로 분리하여, 개별 prophet 승법 모델을 다음 <식 2>와 같이 적합하였음.
- 시간이 지남에 따라 새로운 역이 생기는 경우, 해당 역의 인접한 역의 예측 혼잡도의 평균으로 보정함.

$$y(t) = trend(t) * (1 + s(t) + h(t) + \sum \beta_j x_j(t)) + \epsilon_t$$

- | | | |
|---|---|-------|
| <ul style="list-style-type: none"> • $trend(t)$: 시간 t에서의 추세 함수 • $s(t)$: 연간(yearly), 주간(weekly), 일간(daily) 계절성 성분 • $h(t)$: 공휴일 효과 | <ul style="list-style-type: none"> • $\sum \beta_j x_j(t)$: 시간 t에서 외생변수(기상변수)의 영향. • ϵ_t: 오차항 | <식 2> |
|---|---|-------|

□ 분석 결과 및 검증

○ (하이퍼 파라미터)

- <표 2>는 Prophet 모형의 하이퍼 파라미터 설정값을 나타낸 것으로, 일별, 주간, 연간 계절성을 각각 모델 내부 파생 변수로 추가하여 지하철 혼잡도의 시간적 패턴을 효과적으로 반영하였음.
- 추세 민감도를 0.0005로 지정하여, 급격한 추세 변화를 제한함과 동시에 안정적으로 모델을 학습할 수 있도록 하였음.

표 2. Prophet 하이퍼 파라미터

하이퍼파라미터	설정값	설명
daily_seasonality	True	24시간 주기의 일별 계절성을 반영
weekly_seasonality	True	7일 주기의 주간 계절성을 반영
yearly_seasonality	True	1년 주기의 연간 계절성을 반영
seasonality_mode	multiplicative	계절성과 추세간의 관계를 승법 구조로 설정
changepoint_prior_scale	0.0005	추세의 변화점에 대한 민감도 조절
seasonality_prior_scale	40	계절성 항의 유연성을 조절

○ (Validation 성능 결과)

- (실험 구성) 2021년~2022년 데이터를 학습 데이터로 하여, 2023년을 검증 데이터로 하여, 각 모델별 서울시 지하철 혼잡도를 예측하였음.
- (실험 모델) 본 분석에서 제안하는 모델인 Prophet 이외에 실험 결과 분석을 위해 Boosting 계열의 모델인 XGBoost, LightGBM, CatBoost 3가지 모델을 각각 적합하여 비교하였음.
- (실험 결과) 아래에 <표 3>은 2023년도 검증 데이터를 예측하여, 실제 참값과 비교하여, 각 호선에 대해 상하구분별 RMSE를 나타낸 것임.
- Prophet 모형은 7호선을 제외한 다른 호선에서 RMSE가 다른 비교 모델보다 약 2배 더 높은 반면, 7호선의 경우 CatBoost보다 RMSE가 소폭 낮지만, 성능 차이가 미미하게 나타남.

표 3. Validation RMSE 성능 결과표

		1호선	2호선	3호선	4호선	5호선	6호선	7호선	8호선	평균
상행 (2호선-내선)	Prophet	5.659	6.815	5.903	11.392	6.093	5.288	14.513	6.294	7.744
	XGBoost	11.492	11.365	11.023	12.808	11.780	10.528	15.402	11.152	11.943
	LightGBM	12.864	13.351	11.248	13.635	12.597	11.291	16.842	12.999	13.103
	CatBoost	10.031	10.862	9.171	11.735	10.765	9.975	14.210	10.303	10.881
하행 (2호선-외선)	Prophet	5.535	6.856	6.247	12.614	6.307	4.723	15.316	6.242	7.980
	XGBoost	10.741	12.954	10.831	13.579	12.148	9.759	15.587	10.901	12.062
	LightGBM	12.270	14.097	11.665	14.045	12.610	9.988	16.966	11.713	12.919
	CatBoost	9.570	12.113	9.322	12.706	11.147	9.195	14.786	10.189	11.128

○ (Test 성능 결과)

- (실험 구성) 2021년~2023년 데이터를 학습 데이터로 하여, 본 대회에서 제공하는 2024년의 검증데이터로부터 각 모델별 서울시 지하철 혼잡도를 예측하여 비교하였음.
- (실험 결과) <표 4>와 같이 Prophet 모형의 RMSE가 다른 비교 모델보다 약 3배 이상 높다는 것을 알 수 있음.

표 4. Test RMSE 성능 결과표(대회 제공 데이터)

	Prophet	XGBoost	LightGBM	Catboost
RMSE	5.222	20.446	19.916	21.112

- <그림 4>, <그림 5>는 1호선 상선 구일역을 대상으로 학습 그래프를 나타낸 것임. Prophet 모형은 시간의 주기성을 고려함으로써 실제 혼잡도의 패턴을 더욱 효과적으로 예측한 반면, Boosting 계열의 모델들은 이러한 패턴을 반영하지 못하고 실제 혼잡도의 평균값 수준에서만 예측되는 한계를 보임.
- <그림 6>, <그림 7>은 1호선 상선 구일역에 대한 Prophet 적합 결과를 나타냄. 추세 그래프 결과에 따라, 시간이 지남에 따라 증가하는 지하철 혼잡도의 추세성을 잘 파악하고, 특히 퇴근 시간(17:00~19:00)대에 영향력이 가장 강하다는 것을 알 수 있음.




그림 4. 상선 구일역에 대한 2023년 혼잡도 참값 예측값-비교 그래프(Prophet)




그림 5. 상선 구일역에 대한 2023년 혼잡도 참값 예측값-비교 그래프(Catboost)

○ (Prophet 적합 결과 해석)




그림 6. 4호선 상선 길음역에 대한 추세 그래프




그림 7. 4호선 상선 길음역의 daily 영향력 그래프

○ (출퇴근 시간대에 따른 기상 변수 영향력 분석) - 불쾌지수 그룹 / 강수량 그룹

- (불쾌지수) 2호선은 퇴근 시간대(17:00~19:00)에 불쾌지수가 ‘약간 더움(70~75)’에서 ‘더워서 견딜 수 없음(85 이상)’으로 변화할 때, 평균 혼잡도가 43.0에서 48.6까지 증가함. 출근 시간대(07:00~09:00)에 2호선, 7호선, 8호선 모두 불쾌지수가 ‘더워서 견딜 수 없음’일 때 평균 혼잡도가 각각 26.8, 23.9, 16.9로 크게 감소함.

- (강수량) 퇴근 시간대에 2호선, 7호선은 강수량이 ‘많음(30~60)’에서 ‘매우 많음(60~137)’으로 변화할 때, 평균 혼잡도가 각각 30.4, 15.8까지 크게 감소하는 반면, 출퇴근 시간대를 제외한 기타 시간대에 2호선, 8호선은 강수량이 ‘많음’일 때 평균 혼잡도가 각각 37.6, 32.0까지 크게 증가함.




그림 8. 불쾌지수에 따른 평균 지하철 혼잡도(출퇴근)




그림 9. 강수량에 따른 평균 지하철 혼잡도(출퇴근)

○ (출퇴근 시간대 Spearman 상관분석) - 불쾌지수 그룹, 강수량 그룹

- 전체 데이터에서 혼잡도와 기상 변수 간 상관관계가 매우 낮아 분석에 한계점이 존재하여, 이를 보완하고자 <그림 10>, <그림 11>과 같이 각 호선별 출퇴근 시간대 기반의 불쾌지수 및 강수량 그룹별로 평균 지하철 혼잡도와 평균 기상 변수 간의 상관관계를 분석함.

- (Spearman 상관관계) 비모수적 서열 기반 상관관계 계산 측도로 비선형적 관계와 작은 표본에서도 신뢰성 있는 결과를 제공하는 장점이 있음.

- (불쾌지수 그룹에 의한 상관분석) 풍향, 강수량이 혼잡도와 상관관계가 각각 0.33, 0.11로 양의 상관관계를 보여, 풍향과 강수량의 변화가 지하철 혼잡도 일정 부분에 영향을 미칠 것으로 기대됨.

- (강수량 그룹에 의한 상관분석) 풍향, 상대습도 혼잡도와 상관관계가 각각 0.33, -0.21을 보여, 비 또는 습도 변화가 혼잡도에 일부 영향을 미칠 것으로 기대됨.




그림 10. 불쾌지수 그룹 기반 평균 혼잡도와 기상변수간의 Spearman 상관분석




그림 11. 강수량 그룹 기반 평균 혼잡도와 기상 변수간의 Spearman 상관분석

□ 결론 및 활용 방안

○ (결론)

- 본 분석에서는 지하철 혼잡도에 대한 기상 변수의 영향력을 분석하기 위해 특정 공간 정보 또는 역 주변의 지역적 특성에 국한되지 않고, 오직 기상 변수만의 영향력을 분석했다는 점에서 의미가 있음.

- 통계적 시계열 모형인 Prophet을 활용함으로써 지하철 혼잡도 데이터가 가지는 추세성과 일별 영향력을 효과적으로 포착할 수 있으며, 외생변수로 기상 변수를 추가함으로써 더 나은 예측 성능을 보였음.

○ (한계점)

- Prophet 모형은 일반적으로 다른 모델들에 비해 하이퍼파라미터 개수가 적고 제한되어 있어 성능 향상에 한계점이 있음. 이에 따라 각 역별 승하차 인원, 시간대별 이용객 수, 상권 정보 등과 같은 외부 데이터를 추가로 활용함으로써 지하철 혼잡도와 유동 인구의 패턴을 종합적으로 분석해야 함.

- 지하철 혼잡도와 기상 변수와의 상관성을 파악하기에는 분석의 어려움이 있으므로, 전체적인 상관성보다는 특정 기상 이벤트(대설, 폭우, 태풍 등)를 중심으로 상관성을 분석할 필요가 있음.

○ (활용 방안)

- Prophet으로부터 각 역에 대해 월별, 일별 등의 지하철 혼잡도 패턴과 영향력을 개별적으로 분석할 수 있어, 지하철 운영 계획 수립, 안전 관리, 교통 정보 제공 등 실무 활용에 효과적일 것으로 기대됨.

- 지하철 혼잡도는 주로 시간대에 영향을 많이 받기 때문에, 특정 시점을 기준으로 기상 조건에 따라 실시간 혼잡도 변화량을 예측하는데 도움이 될 것으로 기대됨.

- 기존의 Prophet 모형에 신경망 구조가 결합된 Neural Prophet 모형을 적용하여, 시계열 데이터의 비선형성 또는 급격한 변동성을 보다 효과적으로 반영할 수 있어 예측성능을 향상시킬 수 있을 것임. - [5]

□ 참고 자료

- [1] 연합뉴스 - 이재영(2025.01) “기상청, 기상자료와 지하철 혼잡도 정보 결합 연내 기술 확보”
- [2] 기상청 API 허브 - 지상관측 자료(적설량)
- [3] KCI - 최상기(2013) “기상조건이 대중교통수요에 미치는 영향에 관한 연구”
- [4] Taylor, S. J. and Letham, B. (2018) “Forecasting at scale.” The American Statistician, 72(1), 37-45
- [5] Triebe, Oskar, et al. “Neuralprophet: Explainable forecasting at scale.” arXiv preprint arXiv:2111.15397 (2021).