

기상과 지하철 혼잡도 상관 분석 예측

통계적 시계열 모형 Prophet을 활용한
서울시 지하철 혼잡도 예측 및 기상 변수가 미치는 영향력 분석

목차

1. 분석 배경

2. 분석 데이터

3. EDA

4. 데이터 전처리

5. 모델링

6. 실험 구성 및 결과

7. 결론 및 활용방안

1. 분석 배경

기상청, 날씨 따른 지하철 혼잡도 예측 기술 개발

장훈경 기자 작성 2025.01.27 09:20 조회 392



연합뉴스 - 이재영(2025.01) “기상청, 기상자료와 지하철 혼잡도 정보 결합 연내 기술 확보”

날씨가 대중교통 이용자의 지하철 또는 버스 선택에 미치는 영향 :스마트카드 데이터를 사용하여 The effect of weather on public transportation user's choice of subway or bus : Using smartcard data

이승연¹ · 이영인²

¹서울대학교 환경대학원 환경계획학과, ²서울대학교 환경대학원 환경계획학과

1. 서론

1-1. 연구의 배경 및 목적

교통계획 및 운영에 있어 비와 눈과 같은 날씨는 중요한 요인이다. 일반적으로 기상조건이 좋으면 교통량이 증가하고 정시성이 높아지며 대중교통 수송분담률이 증가한다. 반대로 강우량 및 강수량이 많거나 짙은 안개 등으로 기상 조건이 좋지 못하면 교통량의 감소 및 정시성의 하락, 교통사고 증가, 대중교통 수송분담률 하락을 야기시킨다. 이미 비가 오는 날에는 일반적으로 버스 수요가 감소한다는 기상청의 연구가 있을 만큼 날씨와 대중교통의 연관성에 대한 연구는 과거부터 끊임없이 진행되고 있다. 과거에는 대중교통 이용자들 각각의 데이터가 기록되지 않아 단순 통계량으로 날씨와 대중교통의 관계를 분석하였지만, 최근에는 스마트카드 데이터를 통해 이용자들의 데이터를 기록할 수

결정권을 소유하고 있다. 스마트카드마다 고유 ID가 부여되며 대중교통 이용자들은 승하차 시 단말기에 카드를 태그함으로써 ID를 통한 승차일시 및 하차일시 등의 많은 데이터들이 기록된다. 구체적인 스마트카드 데이터 항목으로는 환승구간마다의 동수단코드, 차량ID, 승·하차 일시, 승·하차역ID, 통행거리, 통행시간, 통행금액 등을 포함한 총 67개의 항목이 있으며 본 연구에서 사용한 데이터 항목은 표1을 통하여 확인할 수 있다.

표 1. 활용된 스마트카드 데이터 항목			
No	데이터 항목	No	데이터 항목
1	운행일시	6	총통행거리
2	최초승차일시	7	교통수단코드
3	최종하차일시	8	환승횟수
4	최초승차역ID	9	총통행시간
5	최종하차역ID	10	총통행금액


이승연, & 이영인. (2021). 날씨가 대중교통 이용자의 지하철 또는 버스 선택에 미치는 영향: 스마트카드 데이터를 사용하여. 대한교통학회 학술대회지, 544-545.

- 기상청의 날씨에 따라 지하철의 혼잡도 예측 기술 개발
- 폭염, 폭설 등의 극단적인 기상 요건이 자가용 대신 대중교통을 이용하는 수단전이 현상이 관찰되며, 기상 요인이 지하철 이용에 영향을 주는 증거로 볼 수 있음.
- 폭우가 내리는 날은 맑은 날에 비해 지하철을 선택할 확률이 18.6%, 폭설이 내리는 날은 맑은 날에 비해 지하철을 선택할 확률이 15.3% 증가함.

2. 분석 데이터

구분	변수명	내용	범위/단위	출처
제공 데이터	날짜	날짜 및 시각	2021-01-01 ~ 2023-12-31	기본 제공 데이터
	호선	지하철 호선	서울시 지하철 1-8 호선	기본 제공 데이터
	역명	역 명	서울시 지하철 324 역	기본 제공 데이터
	상하구분	지하철 상행 하행 구분	상행/하행/외선/내선	기본 제공 데이터
	기온	정시 기온	°C	기본 제공 데이터
	풍속	정시 10분 평균 풍속	m/s	기본 제공 데이터
	일강수량	0~24시까지의 일 강수량	mm	기본 제공 데이터
	시간강수량	1시간 강수량	mm	기본 제공 데이터
	상대습도	정시 상대 습도	%	기본 제공 데이터
	체감온도	500m 객관분석 자료	°C	기본 제공 데이터
	혼잡도	열차 내 혼잡도	%	기본 제공 데이터
파생 변수	요일	요일 더미 변수	(월, 화, 수, 목, 금)	파생변수
	시간	시간 더미 변수	00~23(시간 구분)	파생변수
	요일*시간	요일·시간 상호작용 변수	-	파생변수
	풍향-sin	풍향 변수 sin 함수 변환	-	파생변수
	풍향-cos	풍향 변수 cos 함수 변환	-	파생변수
	불쾌지수	기온과 상대습도 간의 관계	-	파생변수
	공휴일	공휴일 여부	공휴일 여부: 1/0	파생변수
	공휴일*시간	공휴일·시간 상호작용 변수	-	파생변수
외부 데이터	적설량	적설량	(cm)	기상청 API 허브

3. EDA



- 일 평균 혼잡도가 1~5월, 9~11월 구간에는 평균 혼잡도가 증가하는 패턴




- 일 평균 혼잡도가 6~8월 평균 혼잡도가 다시 감소하는 패턴



- Loess 추세선을 통한 2021~2023년 기간동안의 일 평균 지하철 혼잡도 추세(Trend) 분석

- 2021년, COVID 19 영향으로 지하철 이용량 급감, 2022~2023년, 방역 완화 및 사회 활동 재개로 인한 지하철 이용량 회복

3. EDA



출퇴근 시간대에 따른 지하철 혼잡도 분포(Boxplot)

- 1~8호선 모두 퇴근 시간대의 혼잡도가 가장 높고, 다음 출근 시간대, 기타 시간대 순으로 혼잡도가 분포함.
- 2호선은 모든 시간대(퇴근, 출근, 기타)의 혼잡도 중앙값이 가장 높고, 특히 퇴근 시간대에 혼잡도가 두드러짐.
- 1, 3호선은 출-퇴근 시간대에 이상치가 많이 발생하여, 특정 시간대 또는 역에서 극단적인 혼잡 상황이 발생했을 가능성을 시사함.
- 8호선은 서울 동남부 위주의 짧은 노선 특성상 출퇴근 수요가 낮아, 전체 적인 혼잡도가 낮고 이상치도 적게 발생함.

4. 데이터 전처리

1. 결측치 처리

Step 1		Step 2		Step 3	
TIME	Value	TIME	Value	TIME	Value
01:00	-99	01:00	NA	01:00	5
02:00	5	02:00	5	02:00	5
03:00	-99	03:00	7.5	03:00	7.5
04:00	10	04:00	10	04:00	10
05:00	20	05:00	20	05:00	20
06:00	-99	06:00	NA	06:00	20

- Step1. 기상 변수 값 -99는 NA 처리, 풍향 변수는 -99 이외에도 -9.9와 같은 음수 값 또한 NA 처리
- Step2. 각 역단위로 데이터를 그룹화하여, 시간 순으로 재정렬 후 시계열 선형 보간법 적용함.
- Step3. 선형 보간 이후에도 남은 결측값을 양방향 보간법을 적용하여, 나머지 모든 결측치를 대체함.

2. 적설량 외부데이터

변수명	의미(단위)	변수명	의미(단위)
STN_ID	지점번호	LON	경도(degree) / LAT
STN_SP	지점 특성코드 (3자리수)	HT	노장 해발고도 (m)
STN_CD	지점코드	STN_KO	지점명(한글)
STN_AD	관리관서번호	FCT_ID	예보구역코드
LAW_ID	법정동코드	TM	관측시각 (KST)
STN_ID	국내 지점번호	STN_KO	지점명
LAT	위도 (degree)	STN_SP	지점특성
SD	적설값 (cm)	SD_TOT	적설값 (cm)
SD_DAY	일신적설값 (cm)	SD_HR3	3HR 신적설값 (cm)
SD_D01	적설에서 계산한 일신적설값 (cm)	SD_H03	적설에서 계산한 3시간 신적설값 (cm)
SD_H24	적설에서 계산한 24시간 신적설값 (cm)	SD_H01	적설에서 계산한 1시간 신적설값 (cm)
HH:MI	최심값이 처음 나타난 시분 (KST)		

- 기상청 API 허브에서 제공하는 지상관측-적설관측 중 2021~2024년 1시간 단위 적설량을 추출함.
- 지점번호(STN_ID)가 서울에 해당하는 데이터를 선별함.
- 제공된 지하철 혼잡도 데이터와 1시간 단위 기준으로 병합.

4. 데이터 전처리

3. 파생변수 생성


요일 및 시간

One-hot encoding 변수

- 지하철 혼잡도 데이터는 추세성, 요일, 시간 등 강한 시간 주기성을 가지기 때문에 이러한 요소를 반영하고자함.

비선형 풍향 변수

- 풍향은 0~360도 범위의 각도로 주어짐.
- 방향을 선형적으로 표현할 수 없는 부분을 보완하기 위해, 사인(Sin)과 코사인(Cos) 함수로 변환하여, 각도의 주기성과 방향성을 보존한 형태로 재구성함.



요일-시간 상호작용 변수

- One-hot-encoding 된 요일, 시간 변수로부터 요일 * 시간 상호 작용 변수 추가하여 복합적인 시간 패턴을 효과적으로 반영하고자 함.

불쾌 지수 변수

- 고온 다습 환경에서 인간이 느끼는 심리적 불쾌감을 수치화한 지표.
- 지하철 이용과 관련된 간접적인 요인으로 간주함.
- $$\text{불쾌지수} = 0.08 * \text{기온} + 0.01 * \text{상대습도} * (0.99 * \text{기온} - 14.3) + 46.3$$

5. 모델링

Prophet 시계열 모형

Taylor, S. J. and Letham, B. (2018) "Forecasting at scale." The American Statistician, 72(1), 37-45

- 기상 변수가 지하철 혼잡도에 미치는 영향력을 파악하기 위해, 외생 변수로 기상변수로 설정함.
- 지하철 상하행별 역명 모두 개별적으로 분리하여, 개별 Prophet 승법 모형을 적합하였음.
- 시간이 지남에 따라 새로운 역이 생기는 경우, 해당 역의 인접한 역의 예측 혼잡도의 평균으로 보정함.

$$y(t) = trend(t) * (1 + s(t) + h(t) + \sum \beta_j x_j(t)) + \epsilon_t$$

- $trend(t)$: 시간 t 에서의 추세 함수
 - $s(t)$: 연간(yearly), 주간(weekly), 일간(daily) 계절성 성분
 - $h(t)$: 공휴일 효과
- $\sum \beta_j x_j(t)$: 시간 t 에서 외생변수(기상변수)의 영향.
 - ϵ_t : 오차항

Prophet 모형

하이퍼파라미터	설정값	설명
daily_seasonaility	True	24시간 주기의 일별 계절성을 반영
weekly_seasonality	True	7일 주기의 주간 계절성을 반영
yearly_seasonality	True	1년 주기의 연간 계절성을 반영
seasonality_mode	multiplicate	계절성과 추세간의 관계를 승법 구조로 설정
changepoint_prior_scale	0.0005	추세의 변화점에 대한 민감도 조절
seasonality_prior_scale	40	계절성 항의 유연성을 조절

하이퍼 파라미터 설정값

하이퍼 파라미터 설정

- 일별(daily), 주간(weekly), 연간(yearly) 계절성을 각각 모델 내부 파생변수로 추가하여, 지하철 혼잡도의 시간적 패턴 반영함.
- 추세 민감도(change prior scale)를 0.0005로 지정하여, 급격한 추세 변화를 제안하고, 동시에 안정적인 학습을 보장하도록 함.

6. 실험 구성 및 결과

		1호선	2호선	3호선	4호선	5호선	6호선	7호선	8호선	평균
상행 (2호선-내선)	Prophet	5.659	6.815	5.903	11.392	6.093	5.288	14.513	6.294	7.744
	XGBoost	11.492	11.365	11.023	12.808	11.780	10.528	15.402	11.152	11.943
	LightGBM	12.864	13.351	11.248	13.635	12.597	11.291	16.842	12.999	13.103
	CatBoost	10.031	10.862	9.171	11.735	10.765	9.975	14.210	10.303	10.881
하행 (2호선-외선)	Prophet	5.535	6.856	6.247	12.614	6.307	4.723	15.316	6.242	7.980
	XGBoost	10.741	12.954	10.831	13.579	12.148	9.759	15.587	10.901	12.062
	LightGBM	12.270	14.097	11.665	14.045	12.610	9.988	16.966	11.713	12.919
	CatBoost	9.570	12.113	9.322	12.706	11.147	9.195	14.786	10.189	11.128

Validation 성능 결과

- 2021~2022년 학습 데이터 2023년 검증 데이터
- Boosting 계열의 모델 XGBoost, LightGBM, CatBoost 3가지 모델을 비교군 모델로 선정.


- Prophet 모형은 7호선을 제외한 다른 호선에서 RMSE가 다른 비교 모델보다 약 2배 더 높음.
- 반면, 7호선의 경우 CatBoost보다 RMSE가 소폭 낮지만, 성능 차이가 미미하게 나타남.

Test 성능 결과


	Prophet	XGBoost	LightGBM	Catboost
RMSE	5.222	20.446	19.916	21.112

- 2021~2023년 학습 데이터 2024년 테스트 데이터
- Prophet 모형의 RMSE가 다른 비교 모델보다 약 3배 이상 높다는 것을 알 수 있음.
- Validation 성능 결과(2021~2022년 학습 기준)와 비교하면, 코로나 19이후 회복된 혼잡도 양상이 반영된 2023년 데이터를 더 추가로 학습함으로써, 혼잡도의 시간적 주기성이 잘 반영되어, Test 성능 결과에서 RMSE가 더 높게 나오는 것을 알 수 있음.


6. 실험 구성 및 결과




상선 구일역에 대한 2023년 혼잡도 참값-예측값 비교 그래프(Prophet)



상선 구일역에 대한 2023년 혼잡도 참값-예측값 비교 그래프(CatBoost)



상선 길음역에 대한 추세 그래프



상선 길음역에 대한 Daily 영향력 그래프


6. 실험 구성 및 결과

분석의 한계점


- 시간 의존성: 대부분 지하철 혼잡도의 변동은 대부분 시간 의존성으로 인해 기상변수와 혼잡도간의 영향력을 파악하기에는 한계점이 존재함.

기상 조건에 따른 평균 지하철 혼잡도 영향력 분석의 타당성

- 기상 조건(불쾌지수 그룹, 강수량 그룹)에 따라 평균 혼잡도를 집계하여 분석하는 것이 타당함.
- 2호선, 7호선, 8호선에 해당하는 각 지하철 역을 불쾌지수/강수량 그룹에 따라 지하철 혼잡도의 평균 변화량을 분석함.



불쾌지수 그룹에 따른 지하철 혼잡도 평균 변화량



강수량 그룹에 따른 지하철 혼잡도 평균 변화량

7. 결론

- 지하철 혼잡도에 대한 기상 변수의 영향력을 분석하기 위해 특정 공간 정보 또는 역 주변의 지역적 특성에 국한되지 않고, 오직 기상 변수만의 영향력을 분석했다는 점에서 의미가 있음.
- Prophet 모형으로부터 지하철 혼잡도가 데이터가 가지는 추세성과 일별 영향력을 효과적으로 학습하고, 외생변수로 기상 변수를 추가함으로써 더 나은 예측 성능을 보임.
- Prophet 모형은 하이퍼 파라미터 개수가 상대적으로 적고 제한되어 있어, 성능 향상에 한계점이 존재함.
- 각 역별 승하차 인원, 시간대별 이용객 수, 상권 정보 등과 같은 외부 데이터를 추가로 활용함으로써 지하철 혼잡도와 유동 인구의 패턴을 종합적으로 분석해야할 필요가 있음.
- 기상변수와 지하철 혼잡도간의 비선형적인 관계로 인한 상관계수가 매우 낮아 분석의 어려움이 존재함.

7. 기대 효과 및 활용 방안

- 각 지하철 혼잡도 패턴과 영향력을 개별적으로 분석할 수 있어, 지하철 운영 계획 수립, 안전관리, 교통 정보 제공 등 실무 활용에 효과적일 것으로 기대됨.
- 지하철 혼잡도의 대부분의 변동은 시간 의존성에 영향을 받기 때문에, 기상 조건 상황에 따라 지하철 혼잡도의 평균 변화를 파악하는 것이 타당함.
- 지하철 혼잡도와 기상 변수와의 관계는 선형 관계를 파악하기에는 한계점이 존재하므로, Prophet 모형에 신경망 구조가 결합된 Neural Prohphet 모형을 적용하여, 혼잡도와의 비선형 관계 또는 급격한 변동을 보다 효과적으로 반영할 수 있을 것으로 기대됨.